

UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA (UTEC)

Curso de Data Mining • Prof. Heider Sanchez

---

## Minería de Datos Masivos sobre Yelp

Influencia, comunidades, segmentación y recomendación en el ecosistema de restaurantes

---

### Proyecto 2: Minería de Datos Masivos

Grafos, Clustering, Recomendación y Análisis Avanzado

### Autores

Alejandro Rojas • Johar Barzola • Nahia Escalante

## Resumen

Construimos un pipeline integral de minería de datos masivos sobre el Yelp Open Dataset (6.99 millones de reseñas, 150,346 negocios, 1.99 millones de usuarios) que responde una pregunta central del ecosistema de restaurantes: *¿quién influye, cómo se agrupan los locales y qué recomendarle a quién?* Los algoritmos del curso se implementan a mano en NumPy (sin scikit-learn, SciPy ni NetworkX); Spark y Parquet se reservan para la ingeniería de datos. El diseño combina análisis exacto donde la escala lo permite (restaurantes de tres mercados completos: Philadelphia, Tampa y New Orleans; 29,314 locales y 2.67 millones de reseñas) con análisis aproximado con garantías donde no (stream completo de 20.35 millones de eventos). Los hallazgos principales: la influencia estructural no coincide con la popularidad (Spearman 0.99 para PageRank frente a 0.67 para HITS respecto al conteo de reseñas); los restaurantes forman seis perfiles operativos solapados, no fronteras rígidas; el recomendador más preciso es el que peor diversifica (top-popular, NDCG@10 0.259, cobertura 13 %) mientras el filtrado colaborativo triplica la cobertura (40 %); y las técnicas de flujo resumen 20.35 millones de eventos en 160 KB manteniendo el 99.4 % de las consultas dentro de la cota teórica.

## 1 Introducción

Las plataformas de opinión generan grafos sociales, flujos de eventos y matrices usuario  $\times$  negocio de escala masiva. Estudiarlas exige no solo aplicar algoritmos, sino elegir el método adecuado a cada escala y evaluar críticamente sus límites. Este proyecto toma el Yelp Open Dataset (6,990,280 reseñas, 150,346 negocios, 1,987,897 usuarios con su red de amistades y 13,356,875 check-ins) y lo somete a las siete partes del enunciado, articuladas por tres preguntas de investigación:

- P1. Influencia (Parte II). ¿Coincide la influencia estructural que revelan PageRank y HITS con las señales visibles (número de reseñas, fans, condición Elite)?
- P2. Segmentación (Partes III y VI). ¿En qué grupos naturales se organizan los restaurantes según sus atributos y su contexto socioeconómico, y qué patrones latentes revela la descomposición de la matriz usuario  $\times$  negocio?
- P3. Recomendación y su contexto (Partes IV, V y VII). ¿Qué tan bien podemos recomendar combinando comportamiento y contenido, cómo late la actividad en el tiempo (pandemia y feriados incluidos) y qué sesgos y problemas de equidad arrastra todo lo anterior?

El enfoque consiste en implementar cada técnica a mano sobre NumPy (PageRank, HITS, Girvan-Newman, K-Means++, DBSCAN, BFR, filtrado colaborativo, TF-IDF, Count-Min Sketch, DGIM, PCA y SVD truncada), validarla contra ejemplos de clase, aplicarla al dataset y cerrar con una auditoría de escalabilidad y equidad. Coherente con el objetivo del curso, la meta es demostrar comprensión profunda de las técnicas mostrando resultados que evidencien su correcta aplicación, no construir un producto de producción. El dataset se enriquece con cuatro fuentes públicas (Census ACS, COVID-19 del *New York Times*, un calendario de feriados y un *crosswalk* geográfico) para dotar de contexto socioeconómico y temporal a las últimas partes.

## 2 Metodología

### 2.1 Datos, limpieza y diseño muestral

El pipeline sigue una arquitectura medallón (Bronze  $\rightarrow$  Silver  $\rightarrow$  Gold) sobre Spark local (semilla global 42, sesión en UTC). La capa *silver* materializa los cinco JSON crudos (8.7 GB) en Parquet tipado con esquemas explícitos y limpiezas documentadas: fechas a *timestamp* UTC, listas de amigos y categorías a *arrays*, corrección del bug histórico de años Elite ("20,20" $\equiv$ 2020), explosión de check-ins a un evento por fila y columnas derivadas *metro* y *es\_restaurante*. La ingesta completa toma menos de dos minutos. La verificación de integridad arroja 0 duplicados de identificadores, 0 reseñas huérfanas y ninguna coordenada, fecha o estrella inválida; la suciedad real se concentra en los atributos de negocio (solo 1 de 39 supera el 60 % de llenado) y en 103 negocios sin categorías (0.07 %), tratados explícitamente.

La decisión metodológica central es de alcance. Varias técnicas del enunciado tienen un costo que crece mucho más rápido que los datos (DBSCAN sin índice es  $O(n^2)$ , Girvan-Newman es  $O(m^2n)$ ), de modo que aplicarlas al dataset completo o las mutilaría o las volvería intratables. Siguiendo el principio del curso de que *cada algoritmo tiene una escala donde se aplica correctamente*, definimos un universo de análisis intensivo: los restaurantes de tres mercados completos (Philadelphia, Tampa y New Orleans), elegidos con la tabla de conteos del notebook 02 bajo tres criterios: (i) masa de datos, pues son el top-3 en reseñas de restaurantes, con 2,671,060 reseñas = 56.5 % de las 4,724,471 del dataset; (ii) diversidad de arquetipos, por la distinta intensidad de reseñas por local (Philadelphia 78, Tampa 91, New Orleans 153); y (iii) cobertura de fuentes externas (los tres cruzan con Census y COVID). El muestreo es por clave, es decir, por mercado completo, no por reseña: dentro de cada mercado se conserva el 100 % de negocios, reseñas, usuarios y amistades, de modo que grafos y matrices quedan íntegros. Muestrear por reseña rompería el grafo social y las co-ocurrencias que el filtrado colaborativo necesita. En contraste, el EDA (Parte I) y el stream (Parte V) se ejecutan sobre el dataset completo (20,347,155 eventos), porque las técnicas de flujo existen precisamente para datos que no caben en memoria. El proyecto queda así montado sobre el contraste que define al *big data*: análisis exacto donde la escala lo permite, aproximado con garantías donde no. Las tablas *gold* resultantes son: negocios (29,314), reseñas (2,671,060), usuarios (813,792), aristas sociales (2,527,630), matriz usuario  $\times$  negocio (2,671,060), features de negocio (29,314  $\times$  30) y el stream de eventos (20,347,155).

## 2.2 Técnicas y justificación

*Grafo usuario-restaurante (Parte I).* Se mide con un BFS propio sobre representación CSR: densidad bipartita  $1.12 \times 10^{-4}$  (0.011 % de celdas llenas) y, por *double sweep* con cuatro semillas, un diámetro (cota inferior)  $\geq 10$  con distancia media  $\approx 6.9$  saltos. El diámetro exacto exigiría un BFS desde cada uno de los 843 k nodos; se reporta honestamente como cota.

*Grafos y ranking (Parte II).* PageRank se implementa con Power Iteration y Google Matrix (teleporte  $\beta = 0.85$ ), validado contra el ejemplo de clase “The Web in 1839”; HITS con refuerzo mutuo hub/authority y normalización  $L_2$ . Se aplican a dos grafos (la red social de amistades y el bipartito usuario  $\rightarrow$  negocio), eligiendo con evidencia cuál conviene a cada uno. Las comunidades se detectan sobre un grafo de co-reseña de restaurantes con Girvan-Newman y modularidad  $Q$  (principal, sobre un subgrafo justificado por su costo  $O(m^2n)$ ) y un greedy de modularidad (CNM) como contraparte escalable, comparados por la misma  $Q$ . Louvain se omite por no estar en el material del curso.

*Clustering (Parte III).* Sobre las 42 features estandarizadas de restaurante (atributos de Yelp más contexto ACS; geografía excluida), se implementan K-Means++ ( $k$  por codo y silueta), DBSCAN ( $\epsilon$  y  $\text{minPts}$  por *k-distance plot*) y BFR (Discard/Compression/Retained sets, distancia de Mahalanobis), comparados con SSE, silueta, *purity* y NMI contra el mercado como etiqueta externa. Se eligen dos de los tres avanzados que pide la rúbrica (DBSCAN y BFR) además de K-Means++.

*Recomendación (Parte IV).* Sobre un split temporal sin fuga (entrenamiento  $\leq 2018$ , validación 2019, test 2020-21), se construyen filtrado colaborativo item-item (Pearson centrado más baseline regularizado  $\mu + b_u + b_i$  y *shrinkage*), un modelo de contenido TF-IDF de reseñas y categorías, y un híbrido ponderado cuyo peso  $\alpha$  se calibra en validación. Se evalúa con Precision@10, Recall@10, NDCG@10, RMSE y MAE, con intervalos *bootstrap*, contra baselines aleatorio y top-popular, midiendo además cobertura y novedad. El contexto ACS se excluye del recomendador y se reserva para la auditoría de equidad.

*Flujos (Parte V).* Se procesan los 20.35 M de eventos en una pasada con memoria acotada: ventanas deslizantes exactas de 1h/4h/24h, Count-Min Sketch con garantía  $\hat{f}(x) \leq f(x) + \epsilon N$ , y DGIM como técnica adicional para contar horas activas en la última semana con memoria sublineal. Los cruces con COVID y Mardi Gras aportan contexto exógeno.

*Reducción de dimensionalidad (Parte VI).* PCA por covarianza y autodescomposición sobre


las 42 features (umbral de 90 % de varianza, *loadings*, proyecciones 2D/3D) y SVD truncada aleatoria sobre una matriz TF-IDF dispersa. Siguiendo la advertencia del curso, SVD se aplica a TF-IDF (donde el cero significa ausencia real) y no a la matriz de ratings, cuyos huecos son datos no observados.

*Análisis crítico (Parte VII).* Se cuantifican exactitud frente a eficiencia (benchmark de kernels y huella de memoria), concentración de la voz (Gini), exposición de rankings y recomendaciones, y la vulnerabilidad a spam, conectando cada resultado de las Partes I a VI con su riesgo y mitigación.

### 3 Resultados


#### 3.1 Influencia: popularidad $\neq$ autoridad

PageRank [10] converge en 45 iteraciones sobre la red social ( $\|\Delta r\|_1 < 10^{-6}$ ) y en 89 sobre el bipartito; HITS [7] en 58. Sobre el grafo bipartito, PageRank prácticamente recupera la popularidad: su correlación de Spearman con el número de reseñas es 0.99, y su ranking lo dominan los gigantes turísticos de New Orleans (Oceana Grill, Acme Oyster House). HITS, en cambio, reordena: la correlación de la autoridad con el volumen cae a 0.674, y solo 2 de los 15 primeros coinciden con PageRank (Figura 1). El *top* de *authorities* pasa a estar dominado por Philadelphia (Reading Terminal Market, Zahav, El Vez): un *authority* es un restaurante avalado por buenos *hubs*, es decir, reseñadores Elite muy activos, no por volumen bruto. En la red social HITS degenera (hub = authority, Spearman 1.0), lo que confirma que el bipartito es su hogar natural y el social el de PageRank.



**Figura 1.** Ranking de restaurantes por PageRank (izq.,  $\approx$  popularidad, dominan los gigantes de New Orleans) frente a HITS *authority* (der., dominan restaurantes de Philadelphia avalados por reseñadores Elite). Solo 2 de 15 coinciden: la autoridad no es popularidad.


La detección de comunidades ilustra el valor de iterar con evidencia. Definir la arista de co-reseña por el conteo crudo de reseñadores comunes produce un grafo casi completo (10,052 aristas, grado medio 134) y modularidad  $\approx 0$ : el conteo confunde solapamiento con tamaño. Al normalizar con el índice de Jaccard el grafo se dispersa (grado medio 8) y emergen micro-mercados. Comparando por la misma  $Q$ , el greedy CNM [3] gana ( $Q = 0.396$ , 33 comunidades) sobre Girvan-Newman [9] ( $Q = 0.294$ ). Las cuatro comunidades grandes segmentan el *dining* de Philadelphia por estilo y precio, no por popularidad: clásicos icónicos (Reading Terminal, Pat's, Geno's), alta cocina de autor (Morimoto, Amada), *trendy* de gama alta (Zahav, Barbuzzo, 4.23 estrellas) y casual de barrio (Monk's, Sabrina's). La matriz de mezcla inter-comunidad añade un matiz que la  $Q$  global escondía (Figura 2): tres micro-mercados son cohesivos (conductancia de 0.22 a 0.30), pero la alta cocina de autor funciona como puente (conductancia 0.58: 70 aristas hacia el casual y 46 hacia lo *trendy*, más que sus 44 internas), mientras el micro-mercado turístico es el más aislado.



**Figura 2.** Red de co-reseña (Jaccard) de los restaurantes de Philadelphia, coloreada por comunidad y con el tamaño del nodo proporcional a su PageRank. Emergen cuatro micro-mercados por estilo y precio; la comunidad de alta cocina de autor actúa como puente entre segmentos.

### 3.2 Segmentación: seis perfiles operativos, no fronteras rígidas

K-Means++ [1] recorre  $k = 2 \dots 10$ . El método del codo es intrínsecamente visual: sobre la curva de SSE frente a  $k$ , el punto de aplanamiento se lee en  $k = 6$  (Figura 3), donde además los seis segmentos resultan interpretables. Se adopta ese valor: un detector automático del codo devuelve  $k = 5$  y la silueta favorece  $k = 2$ , de modo que la diferencia es de una sola unidad frente al codo y no altera la lectura posterior. El empate técnico entre  $k = 5$  y  $k = 6$  (distancias a la recta 0.166 vs 0.150) confirma que ambos son defendibles. El resultado son seis segmentos (servicio completo con bar y reservas; casual económico orientado a *delivery*; baja información y actividad; destinos consolidados; pequeños de baja tracción; y casuales bien valorados), con SSE por punto 28.16 y silueta  $\approx 0.095$ : perfiles útiles pero solapados. La silueta por cluster lo confirma: el segmento más nítido alcanza 0.226 sin asignaciones negativas, mientras otro concentra  $\sim 36\%$  de casos fronterizos. La *purity* frente al mercado es 0.58 (reflejo del peso base de Philadelphia, 58% del universo) y el NMI  $\approx 0.007$ , lo que demuestra que los segmentos no son ciudades disfrazadas.



**Figura 3.** Selección de  $k$  para K-Means++: método del codo sobre la SSE (izq.) y coeficiente de silueta (der.) en el barrido  $k = 2 \dots 10$ . La lectura visual del codo señala  $k = 6$  (aplanamiento de la curva), valor adoptado por interpretabilidad; un detector automático fijaría  $k = 5$  y la silueta  $k = 2$ .

La comparación con los otros dos métodos (Tabla 1) es reveladora. DBSCAN [6], sobre una muestra reproducible de 6,000 puntos por su costo  $O(n^2)$ , colapsa en un único cluster gigante con 7.7% de ruido y silueta indefinida: evidencia directa de la concentración de distancias en 42 dimensiones (la maldición de la dimensionalidad). BFR [2], en cambio, procesa los 29,314 casos por bloques de 4,000 y recupera seis grupos con solo 0.75% de *outliers*, sacrificando algo de silueta (0.056) a cambio de escalar sin matriz densa; su acuerdo con K-Means++ es del 65% tras alinear identificadores. Una lente PCA común (PC1 y PC2 retienen 32.4%) muestra a

K-Means++ y BFR con estructuras relacionadas y a DBSCAN conectando casi toda la nube.

**Tabla 1.** Comparación de los tres métodos de clustering sobre las 42 features de restaurante. DBSCAN se evalúa sobre una muestra reproducible de 6,000 puntos por su costo  $O(n^2)$ ; su silueta es indefinida al formar un único cluster. Fuente: `comparativa_clustering.parquet`.


| Método    | Alcance    | Clusters | Outliers (%) | SSE/punto | Silueta | Purity | NMI    |
|-----------|------------|----------|--------------|-----------|---------|--------|--------|
| K-Means++ | universo   | 6        | 0.00         | 28.16     | 0.095   | 0.578  | 0.0074 |
| DBSCAN    | muestra 6k | 1        | 7.67         | 39.43     | —       | 0.584  | 0.000  |
| BFR       | universo   | 6        | 0.75         | 28.38     | 0.056   | 0.578  | 0.0067 |

### 3.3 Recomendación: el más preciso es el que peor diversifica

La validación de 2019 elige un híbrido equilibrado ( $\alpha \approx 0.5$ ): combinar filtrado colaborativo [11] y contenido (NDCG@10 0.244) supera a cualquiera de los dos puros (contenido 0.208; CF puro 0.177). En test, con candidatos *in-market* barajados para no premiar el orden posicional, aparece el hallazgo central (Tabla 2, Figura 4): el baseline top-popular es el más preciso (NDCG@10 0.259) pero el que peor reparte la exposición (cobertura del catálogo 13 %), mientras el filtrado colaborativo triplica la cobertura (40 %) cediendo precisión (0.176); el híbrido  $\alpha=0.5$  se sitúa en medio (0.238). En predicción de *rating*, el baseline regularizado gana con RMSE 1.24 (MAE 0.997) frente al CF (RMSE 1.31) y a la media global (1.38). El análisis de *cold-start* es consistente: para usuarios con 1 o 2 interacciones el CF colapsa (NDCG@10 0.078), pero el híbrido con conmutación a contenido y popularidad lo recupera a 0.174.

**Tabla 2.** Evaluación de recomendación en el conjunto de test (candidatos *in-market* barajados,  $K = 10$ , intervalos *bootstrap* 95 %). El más preciso (top-popular) es el que peor diversifica; el filtrado colaborativo triplica la cobertura. RMSE y MAE corresponden a la predicción de *rating*. Fuente: `metricas_recomendacion.parquet` y `07_recomendacion_hibrida.ipynb`.

| Modelo                          | P@10  | R@10  | NDCG@10 | Cobertura | Novedad | RMSE | MAE   |
|---------------------------------|-------|-------|---------|-----------|---------|------|-------|
| Random                          | 0.025 | 0.085 | 0.051   | 43.7 %    | 15.94   | —    | —     |
| Top-popular                     | 0.103 | 0.386 | 0.259   | 13.0 %    | 12.51   | —    | —     |
| CF item-item                    | 0.065 | 0.219 | 0.176   | 40.1 %    | 14.99   | 1.31 | 1.03  |
| Content TF-IDF                  | 0.075 | 0.285 | 0.192   | 33.8 %    | 14.67   | —    | —     |
| Híbrido $\alpha=.5$             | 0.087 | 0.320 | 0.238   | 33.9 %    | 14.31   | —    | —     |
| Baseline reg. ( <i>rating</i> ) | —     | —     | —       | —         | —       | 1.24 | 0.997 |




**Figura 4.** Tensión precisión-diversidad: NDCG@10 frente a la cobertura del catálogo (tamaño del círculo = novedad media). El top-popular maximiza precisión con cobertura mínima (13 %); el filtrado colaborativo cubre el 40 % del catálogo cediendo precisión; el híbrido equilibra ambos.

### 3.4 Flujos: memoria convertida en error controlado, con contexto exógeno

Las ventanas exactas de 1h/4h/24h establecen la referencia y revelan un pico de 1,044 eventos por hora. El Count-Min Sketch [4] resume los 20.35 M de eventos: con  $w = 4096$  y  $d = 5$  usa 160 KB, mantiene el 99.4 % de las consultas dentro de la cota  $\varepsilon N$  y recupera el 95 % del Top-20; duplicar el ancho ( $w = 8192$ , 320 KB) recupera el 100 % (Figura 5, izq.). El error p95 queda por debajo de la cota teórica, que se aprieta al aumentar el ancho, mientras el *overlap* de *heavy hitters* se estabiliza con menos de 0.3 MB. DGIM mantiene solo 10 u 11 *buckets* con un MAE de 1.76 a 2.15 horas por semana, suficiente para detectar cambios de régimen.

El contexto exógeno confirma que la actividad no puede atribuirse solo a la calidad del restaurante. Durante el confinamiento de marzo a mayo de 2020, los check-ins caen a entre 14.8 % y 33.1 % del nivel de 2019 según el mercado, mientras las reseñas caen menos (la presencia física se desploma más que la opinión). El experimento natural de Mardi Gras (Figura 5, der.) valida las ventanas: el índice mediano del día del evento alcanza 187 en New Orleans frente a 97 y 101 en los mercados placebo (Philadelphia y Tampa); en 2021 el pico relativo persiste aunque el volumen absoluto cae 71 % por efecto de la pandemia.

CMS: el p95 queda bajo  $\varepsilon N$ ; la garantía es probabilística por consulta



**Figura 5.** Minería de flujos (Parte V). *Izquierda:* Count-Min Sketch; el sobreconteo p95 queda bajo la cota  $\varepsilon N$  y se aprieta al aumentar el ancho  $w$ ; el Top-20 de *heavy hitters* se recupera con menos de 0.3 MB (garantía probabilística por consulta, de modo que el error máximo puede superar la cota). *Derecha:* experimento natural de Mardi Gras; el índice de check-ins por día relativo al evento (día comparable = 100) solo muestra pico en New Orleans, validando que las ventanas capturan la estacionalidad por eventos.


### 3.5 Reducción de dimensionalidad: la señal ilumina, pero también se borra

PCA sobre las  $29,314 \times 42$  features muestra que la estructura no vive en pocos ejes: PC1 y PC2 retienen solo 32.4 % de la varianza y hacen falta 25 de 42 componentes para superar el 90 % (Figura 6, error relativo de reconstrucción 0.309 en ese umbral). Los ejes son interpretables: PC1 captura la documentación digital del negocio (atributos presentes frente a ausentes), PC2 el precio y el servicio de bar y mesa, y PC3 y PC4 el contexto socioeconómico ACS (ingreso, renta, educación). Un mapa 2D es útil pero deja fuera el 67.6 % de la señal. La SVD truncada sobre la matriz TF-IDF dispersa ( $25,952 \times 3,000$ , 5.22 % de densidad; 31.2 MB en CSR frente a 297 MB densa) confirma que el texto gastronómico tiene una cola larga real: con  $k = 80$  factores captura solo 23.4 % de la energía (error 0.875) pero comprime  $33.6\times$  respecto a la matriz densa. Aun así, los factores son semánticamente claros (pizza y delivery, chino y sushi, mexicano y tacos, *drive-thru* y comida rápida): ejes de cocina, formato y experiencia que emergen sin supervisión.

### 3.6 Escalabilidad, sesgos y equidad


El benchmark recupera empíricamente la teoría: la pendiente log-log del kernel de asignación de K-Means es 1.30 (casi lineal) frente a 2.62 del cómputo de vecindades de DBSCAN (super-cuadrático); representar PageRank con matriz densa exigiría 5.3 TB frente a 60 MB con CSR (Figura 7). La lección, que el algoritmo importa más que el hardware, es directamente el tradeoff exactitud-eficiencia del enunciado. En equidad, la voz está concentrada (Gini 0.590; el top 10 % de usuarios escribe el 54 % de las reseñas del universo), lo que sesga cuanto se aprende de ellos. El filtrado colaborativo mejora la distribución de exposición respecto a top-popular (expone 10,402 negocios, 40.1 % del catálogo, con Gini de exposición 0.239, frente a 3,376 negocios, 13.0 %, y





**Figura 6.** PCA sobre 42 features: varianza explicada individual y acumulada. Se requieren 25 componentes para superar el umbral del 90 % (línea); dos ejes retienen solo 32.4 %, de modo que una proyección 2D descarta el 67.6 % de la señal.

Gini 0.358), pero no borra la historia: aún asigna  $\sim 49\%$  de sus recomendaciones al cuartil de negocios más visibles. El stress test de spam muestra que los negocios con poca historia son mucho más vulnerables: cinco reseñas falsas de 5 estrellas mueven la mediana  $+0.56$  en el cuartil de menos reseñas frente a  $+0.03$  en el de más. Y el contexto ACS revela un sesgo de cobertura: los ZIP de menor ingreso tienen 21.2 % de atributos faltantes y mediana de 25 reseñas, frente a 17.9 % y 38 en los de mayor ingreso.



**Figura 7.** Exactitud frente a eficiencia. Izq.: huella de memoria (representación ingenua frente a diseño usado, escala log) por componente; la dispersión y el procesamiento por bloques evitan terabytes. Der.: factor de crecimiento del costo al multiplicar  $n$  por diez, por clase de complejidad.

## 4 Análisis crítico

Los resultados se sostienen sobre supuestos que conviene explicitar. Primero, el alcance. Trabajar con tres mercados completos no es un atajo sino un diseño muestral por clave que preserva la integridad de grafos y matrices; su límite es que los hallazgos de comunidades y clustering describen el *dining* estadounidense de estos tres mercados y no deben extrapolarse a otros contextos sin recalibrar (transferir la metodología a Lima, por ejemplo, exigiría sustituir la taxonomía de Yelp, el ACS y el vocabulario TF-IDF). El diámetro del grafo ( $\geq 10$ ) y la distancia media (6.9) son cotas y estimaciones por *double sweep*, no valores exactos; se reportan como tales para no inflarlos.

Segundo, por qué unos métodos superaron a otros. El colapso de DBSCAN no es un fallo de implementación (está validado en un ejemplo de juguete) sino la manifestación esperada de la concentración de distancias en 42 dimensiones: DBSCAN necesita un contraste de densidad que el espacio de features de restaurante no ofrece sin reducción previa, y por eso BFR (que asume grupos gaussianos) resulta más apropiado a esta escala. En recomendación, que el top-popular sea el más preciso no debe sobreinterpretarse: la precisión mide aciertos en una lista de candidatos



donde los ítems populares son a priori más probables; el CF paga precisión pero reparte exposición al triple de negocios, y solo mirando cobertura y novedad, no NDCG a secas, se ve el cuadro completo. La elección de  $k = 6$  en clustering responde a la lectura visual del codo (el método es inherentemente gráfico): la curva de SSE frente a  $k$  se aplana en ese punto y los seis segmentos son interpretables. Un detector automático habría fijado  $k = 5$  y la silueta prefiere  $k = 2$ , de modo que la decisión difiere en una unidad respecto al codo y no cambia la conclusión de fondo: perfiles operativos solapados, no fronteras rígidas.

Tercero, los sesgos de los datos. El 67% de reseñas son 4 y 5 estrellas y una minoría escribe la mayoría de ellas; toda métrica de rating y todo recomendador aprende de esa voz concentrada, lo que penaliza a los negocios con poca historia, los mismos que el stress test muestra más vulnerables a la manipulación. El uso del ingreso del ZIP (ACS) como contexto conlleva riesgo de falacia ecológica: es un atributo del vecindario, no del negocio ni del propietario, y se usa solo de forma descriptiva, nunca causal. Las métricas de equidad describen la exposición del sistema; decidir qué nivel es *justo* requiere criterios normativos y la participación de los actores afectados, fuera del alcance técnico.

Cuarto, reproducibilidad y garantías. Todo corre con semilla 42 y resultados persistidos en Parquet; los algoritmos de flujo cambian memoria por error acotado (el error máximo de CMS puede exceder  $\varepsilon N$  porque la garantía es probabilística por consulta individual, matiz que la Figura 5 hace explícito), y la PCA y la SVD cambian dimensiones por pérdida de información cuantificada. Persisten pequeñas inconsistencias de baja severidad (dos corridas distintas de la silueta de clustering y narraciones de tiempo en *markdown* que difieren del *stdout*), documentadas en la validación final; se adoptó como canónica la tabla de comparación dedicada.

## 5 Conclusiones

El proyecto responde sus tres preguntas con evidencia reproducible. Sobre influencia: popularidad, autoridad e influencia son cosas distintas; PageRank sobre el bipartito recupera la popularidad (Spearman 0.99) pero HITS reordena hacia restaurantes avalados por reseñadores serios (0.67), y las comunidades de co-reseña, una vez normalizadas por Jaccard, segmentan por estilo y precio, con la alta cocina de autor actuando como puente entre segmentos. Sobre segmentación: los restaurantes forman seis perfiles operativos solapados (silueta  $\approx 0.10$ , NMI  $\approx 0.007$  con el mercado), no especies discretas; DBSCAN no escala ni discrimina en 42D, mientras BFR conserva la estructura por bloques, y PCA y SVD confirman que la señal tiene una cola larga real (25 de 42 ejes para el 90%; 80 factores SVD capturan solo 23.4% de energía aunque comprimen  $33.6\times$ ). Sobre recomendación y su contexto: la evaluación sin fuga muestra que el más preciso (top-popular) es el que peor diversifica, que el híbrido equilibrado supera a los métodos puros, y que las técnicas de flujo resumen 20.35 M de eventos en 160 KB con el 99.4% de las consultas dentro de la cota, detectando además el efecto de la pandemia y de Mardi Gras.

En cuanto al método más apropiado por tarea: BFR para clustering a escala, HITS (no PageRank) para autoridad en el bipartito, CNM (no Girvan-Newman) para comunidades cuando el costo importa, el híbrido  $\alpha \approx 0.5$  para recomendación equilibrada, y Count-Min Sketch [4] junto con DGIM [5] para conteo aproximado con garantía. Las principales limitaciones son el alcance a tres mercados, la elección interpretativa de  $k$ , las cotas del diámetro y los sesgos de una voz concentrada.

Como trabajo futuro proponemos tres líneas concretas: (i) reducir dimensionalidad *antes* de DBSCAN para rescatar su capacidad de detección de densidad; (ii) incorporar *re-ranking* diverso al híbrido para mitigar el sesgo de exposición que el CF reduce pero no elimina; y (iii) añadir detección de campañas coordinadas y estimación bayesiana de *rating* para blindar a los negocios con poca historia frente a la manipulación. El marco teórico común a todas las partes es *Mining of Massive Datasets* [8], y los datos provienen del Yelp Open Dataset [14] enriquecido con Census ACS [13] y COVID-19 del *New York Times* [12].

## Referencias

- [1] David Arthur and Sergei Vassilvitskii. k-means++: The advantages of careful seeding. In *Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA)*, pages 1027–1035, 2007.
- [2] Paul S. Bradley, Usama M. Fayyad, and Cory Reina. Scaling clustering algorithms to large databases. In *Proceedings of the 4th International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 9–15, 1998.
- [3] Aaron Clauset, M. E. J. Newman, and Cristopher Moore. Finding community structure in very large networks. *Physical Review E*, 70(6):066111, 2004.
- [4] Graham Cormode and S. Muthukrishnan. An improved data stream summary: The count-min sketch and its applications. *Journal of Algorithms*, 55(1):58–75, 2005.
- [5] Mayur Datar, Aristides Gionis, Piotr Indyk, and Rajeev Motwani. Maintaining stream statistics over sliding windows. *SIAM Journal on Computing*, 31(6):1794–1813, 2002.
- [6] Martin Ester, Hans-Peter Kriegel, Jörg Sander, and Xiaowei Xu. A density-based algorithm for discovering clusters in large spatial databases with noise. In *Proceedings of the 2nd International Conference on Knowledge Discovery and Data Mining (KDD)*, pages 226–231, 1996.
- [7] Jon M. Kleinberg. Authoritative sources in a hyperlinked environment. *Journal of the ACM*, 46(5):604–632, 1999.
- [8] Jure Leskovec, Anand Rajaraman, and Jeffrey D. Ullman. *Mining of Massive Datasets*. Cambridge University Press, 3 edition, 2020. Disponible en <http://www.mmids.org>.
- [9] M. E. J. Newman and Michelle Girvan. Finding and evaluating community structure in networks. *Physical Review E*, 69(2):026113, 2004.
- [10] Lawrence Page, Sergey Brin, Rajeev Motwani, and Terry Winograd. The PageRank citation ranking: Bringing order to the web. Technical Report 1999-66, Stanford InfoLab, 1999.
- [11] Badrul Sarwar, George Karypis, Joseph Konstan, and John Riedl. Item-based collaborative filtering recommendation algorithms. In *Proceedings of the 10th International Conference on World Wide Web (WWW)*, pages 285–295, 2001.
- [12] The New York Times. Coronavirus (covid-19) data in the united states. <https://github.com/nytimes/covid-19-data>, 2021. Licencia CC BY-NC.
- [13] U.S. Census Bureau. American community survey (acs) 5-year estimates 2022. <https://www.census.gov/programs-surveys/acs>, 2022.
- [14] Yelp Inc. Yelp open dataset. <https://business.yelp.com/data/resources/open-dataset/>, 2021. Uso académico bajo Dataset User Agreement.